ElasticSearch

- Büyük verileri analiz etme, bunların arasında arama yapma ve önerme gibi işlemleri gerçekleştiren Java ile geliştirilmiş güçlü, esnek ve performanslı bir teknolojidir.-
- Apache Lucene altyapısına sahip olduğu için mükemmel bir full-text search yeteneğine sahiptir.
- Document-based bir yapıya sahiptir ve bu nedenle verileri JSON formatında tutar.
- Tüm search, CRUD ve analiz işlemleri sağladığı Rest API üzerinden rahatlıkla yapılabilir.

Search Engine Candidates:

- Elasticsearch
- Solr
- InfluxDB
- TypeSense
- Algolia
- Sphix

For more:

- https://www.educba.com/elasticsearch-alternatives/
- https://www.linuxlinks.com/searchengines/

Solr vs **Elasticsearch**

Both Solr and Elasticsearch write indexes in Lucene. But, since differences exist in sharding and replication (among other features), there are also differences in their files and architectures. Additionally, Elasticsearch has native DSL support while Solr has a robust Standard Query Parser that aligns to Lucene syntax.
For more: https://logz.io/blog/solr-vs-elasticsearch/

ElasticSearch Features**:**

- **Lots of search options**
- **Document-oriented**
- **Speed**
- **Scalability**

- **Data record**
- **Query fine tuning**
- **RESTful API**
- **Distributed approach**
- **Multi-tenancy**

For more:

- https://www.elastic.co/elastic-stack/features
- https://dzone.com/articles/elastic-search-advantages-case-studies-amp-books

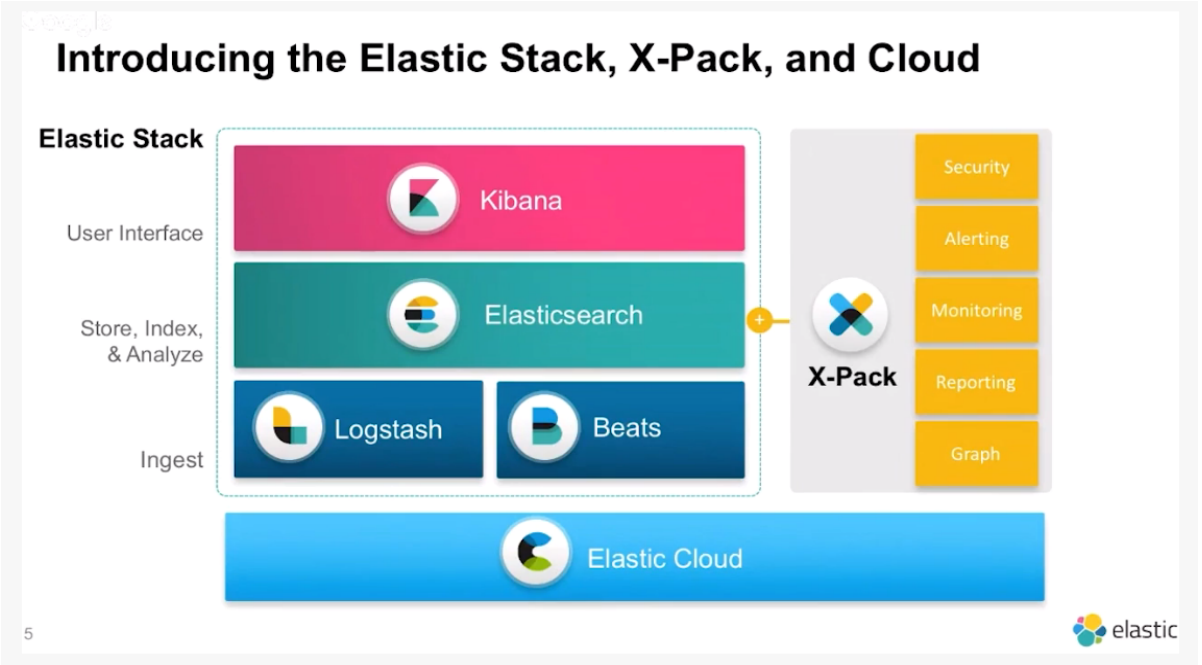

Senaryomuz üzerinde clientlardan topladıkları logları elkstack sunucumuza yollamakla yükümlü aracımız ***Beats*** , toplanan bu logları bir sunucu içinde derleyip üzerinde yapılması gereken bir dönüştürme ve anlam kazandırma işlemini gerçekleştiren aracımız ***Logstash*** ,bu logları indexlendirerek aranabilir ve analiz edilebilir hale dönüştüren aracımız ***Elasticsearch*** ve tüm bu yapılan detaylı çalışmayı bizlere görselleştiren aracımız ***Kibana*** olarak karşımıza çıkmaktadır.

- Her node'da 1 adet ElasticSearch çalışmaktadır. Her node birbiri ile haberleşir.
- Kibana konfigürasyonlarını Elastic Search üzerinde tutar.
- LogStash pipeline: Inputs -> Filters -> Outputs
- Beats: Dosyaları, log'ları toplar LogStash veya ElasticSearch'e aktarır. FileBeat,MetricBeat, PacketBeat,WinLogBeat,AuditBeat,HeartBeat.

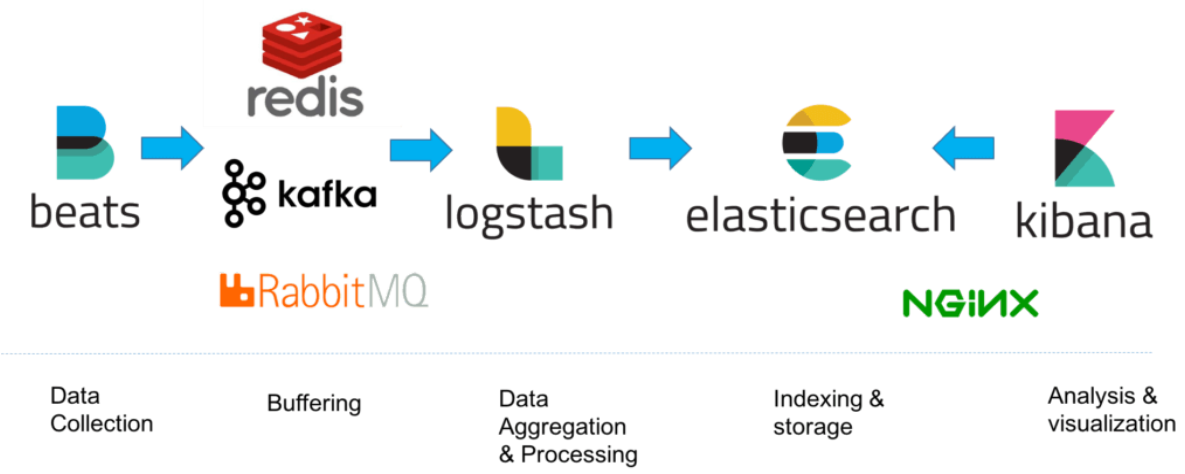

Index: Index'ler, Json veriler topluluğudur. Index'leri biz belirleriz. Bir kelime veya cümle olarak tanımlayabiliriz. Eklenen her döküman için her bir kelime için hangi döküman ya da dökümanlarda o kelimenin olduğu bilgisini tutan bir indeksleme sistemi vardır.
Aramayı çok kolay bir hale getiren Apache Lucene'in Inverted Index'leri ve içerisindeki verinin şemasını tanımlayan mapping'i içerirler.
Bir veri insert edilirken Apache Lucene alt yapısı kullanılarak index'lenir.

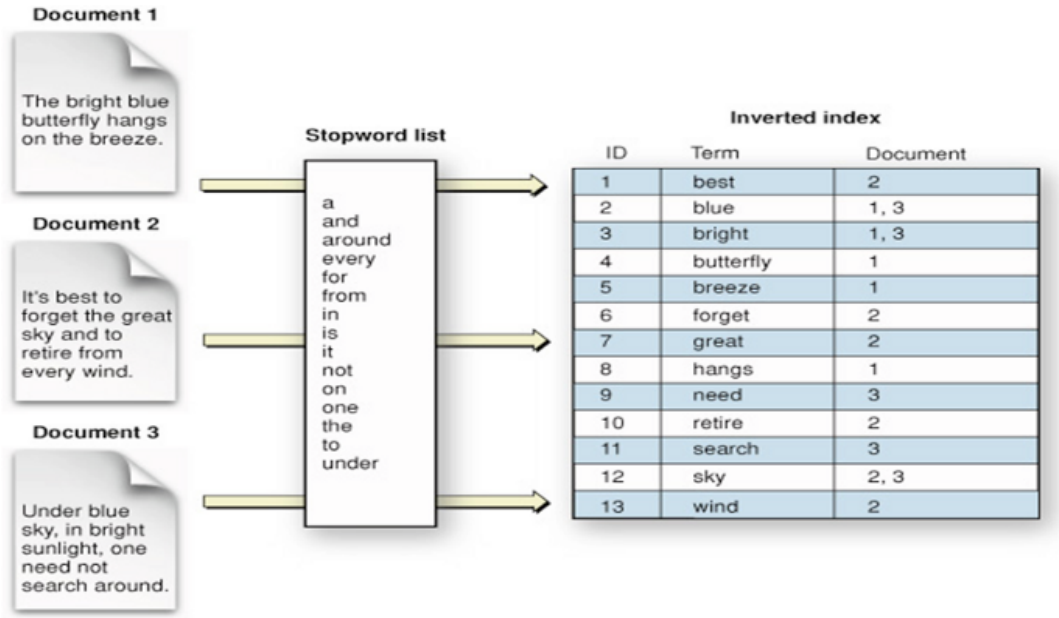

Mapping: İlgili dökümanın arama motoruna nasıl aktarılacağını tanımıdır. Index'ler iken o verinin türünü bu şekilde tanımlarız.

```
{
    "animal": {
        "badger": {
            "properties": {
                "bio": {
                    "type": "string"
                },
                "name": {
                    "type": "string"
                },
                "role": {
                    "type": "string"
                }
            }
        }
    }
}
```

Types:

- Explicit Mapping: Field'lar ve type'ları önceden tanımlıdır.
- Dynamic Mapping: Field'lar ve type'ları ElasticSearch tarafından otomatik olarak tanımlanır.

Field types,

- Basit Veri tipleri: String, byte, short, integer, long, float, double, boolean, date
- Kompleks veri tipleri: object, nested
- Özel veri tipleri: geo_point, geo_shape, completion

Field Index, full text search'ün bir parçası olsun mu olmasın mıyı belirliyoruz.
Field Analyzer, token filter and tokenizer tanımlarız.

- Character Filters: Remove HTML encoding, convert & to and
- Tokenizer: Split strings on whitespace / punctuation / non-letters
- Token Filter: Lowercasing, stemming, synonmys, stopwords

Document: ElasticSearch'teki her bir kayda denir. Her döküman kendi unique Id'sine sahiptir. Her bir document bir type ve unique id'ye sahiptir ve bir index içerisinde tutulur.

Field: Her döküman içerisindeki alana field denir. RDBMs'teki column'a denk gelir. Bir document birden fazla field'a sahip olabilir.
Type: Aslında Relational Database'lerde tablo' ya denk gelir. product ve user gibi. ES 7.0 dan sonra kaldırılmıştır. Type'ın RDMBs'de tablolara denk geldiğini söylesek de durum tam olarak öyle değil. İlişkisel veritabanında tablolar birbirinden bağımsızdır. Örnek olarak user tablosundaki name field'ı ile product tablosundaki name field'ının bir bağlantısı yoktur. Fakat ElasticSearch'te aynı index altında bulunan field'lar arka planda aynı Lucene field'ına denk gelmektedir. Yani user type'ının name field'ı ile product type'ının name field'ı aynı alanda saklanır. Bu da bir takım sorunlara yol açmaktadır.

Relational Database	Elasticsearch
Schema	Mapping
Database	Index
Table	Type
Row	Document
Column	Field

Cluster: Birden fazla Node'un tutulduğu yapıya denir.
Node: Verilerin depolandığı makinelerin her biridir. Cluster'ların indexleme ve arama yetenekleri, bu node'lar ile gerçekleştirilir.

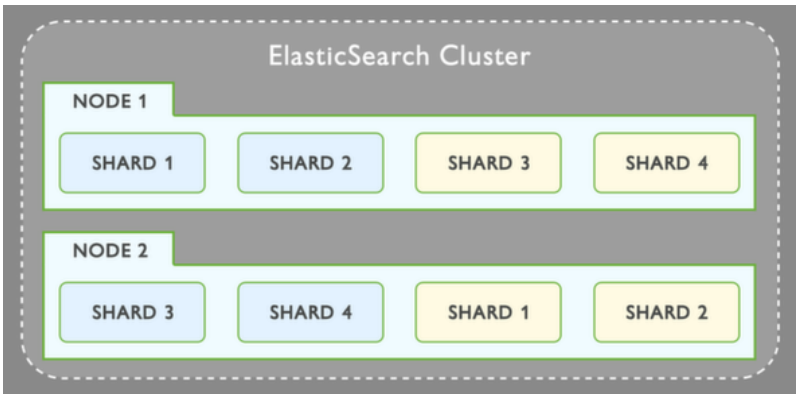

Shard: Shard'lar **Apache Lucene**'in ta kendisidir. Index'lerde çok fazla veri olması performans, ölçeklenebilirlik ve bakım sorunlarına yol açabilir. Bu yüzden index'ler

birer Lucene instance'ı olan shard'lara bölünebilir. Index oluşturulurken shard'ların sayısı belirlenir ve veriler shard'lara dağıtılır.
Shard'lar node'lara bölünür. Böylece işlemler hem dağıtık hem de paralel hale gelmiş olur ve performans artar. İçerik hacmini yatay olarak bölmeye ve ölçeklendiremeye olanak tanır.
Primary shard'ların miktarı daha sonradan değiştirilemiyor. Bunun yerine read için daha fazla replica oluşturulabilir. En kötü durumda yeni bir index oluşturulabilir.

```
PUT /testindex
{
 "settings": {
   "number_of_shards": 3
   , "number_of_replicas": 1
 }
}
```

Bu ayarda 3 tane primary 3 tane replica shard olmak üzere 6 tane shard oluşturuluyor. 5 primary 3 replica için ise toplam 20 shard oluşur.
Replica: Shard' ın devre dışı kalma ihtimaline karşılık index' lerin tutulduğu shard'lar farklı node'lar içerisinde çoklanır.
Write request'leri primary shard'lara yönlendirilir. Oradan replica shard'lara iletilir.
Read request'ler, hem primary hem de replica shard'lara yönlendirilir.

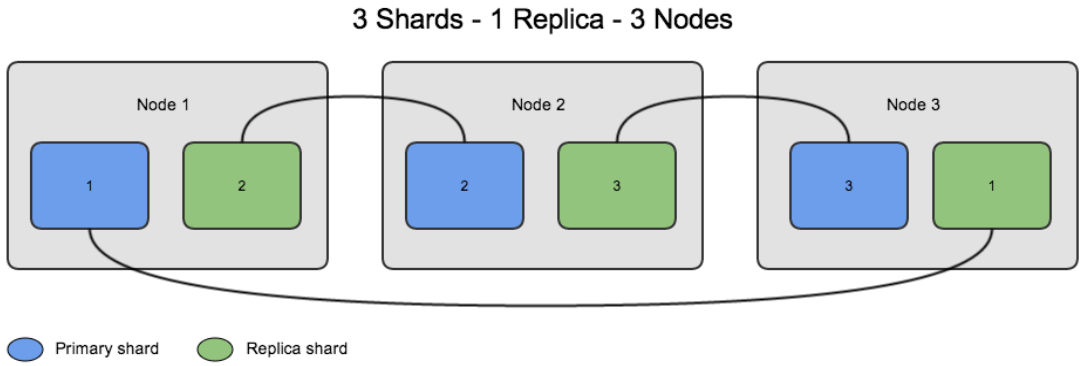

APIs

- Cat API: index, cluster, node, shard gibi bir çok şey ilgili bilgiler görüntülenebilir.
- Cluster API: Cluster ile ilgili bilgiler
- Index API: index bazında create, delete, monitoring, mapping, settings gibi işlerden sorumludur.
- Document API: Dökümanlar üzerinde CRUD operasyonlarını yapmamızı sağlar.

- Search API: Arama yapmak için kullanılır. URI Query ve Query DSL.

Analyzer

ElasticSearch'e yolladığımız dökümanlar hem performans hem de istediğimiz şekilde çalışmasını sağlamak için indexlenmeden önce bir dizi işlemden geçer. Bu işlemlerin bütünü analysis'tir. Bu işlemi yapan kısma ise Analyzer denir.

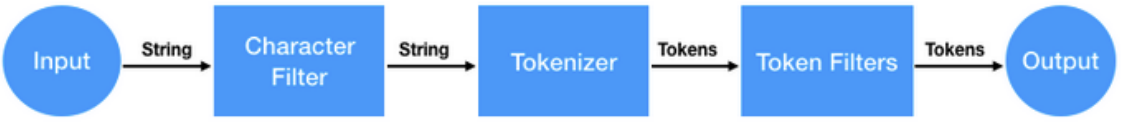

1. Karakter Filtreleme: Daha doğru search sonuçları elde edebilmek için belirli karakterleri farklı karakterlere çevirme işlemidir.
you & me -> you and me
2.Text'i Token'lara Ayrıştırma: Text'e karakter filtresi uygulandıktan sonra, ilgili dökümanın kelime setlerine ayrıştırılması gerekir. Lucene inverted index yapısı gereği dökümanı token adı verilen kelimelere ayrıştırarak işlem yapar. Örneğin; standart tokenizer kullanırsak boşluklara göre token'lara ayrıştırır.
"I like ES" -> tokens: "I", "like", "ES"
3.Token Filtreleme: Token'ları alarak onları ihtiyaca göre modifiye edilmesi işlemidir. lowercase token filterda tüm token'lar küçük harfe çevrilir.
4.Token indexleme: Token'lar token filter'lar üzerinden geçirilir ve inverted index'e yerleştirilir.

Built-in Analyzers
- Standart Analyzer, default geçerli olandır. Standart lowercase token filter'ını ve stok token filter'ını içerir.
- Simple Analyzer,
- Whitespace Analyzer,
- ...

Built-in Tokenizers
- Standart Tokenizer, Gammer based tokenizer'dır. "I like, ES" -> "I", "like", "ES"
- Keyword Tokenizer,
- Letter Tokenizer,
- ...

Built-in Token Filters
- Standart

- Lowercase
- Length
- Stop
- Trim

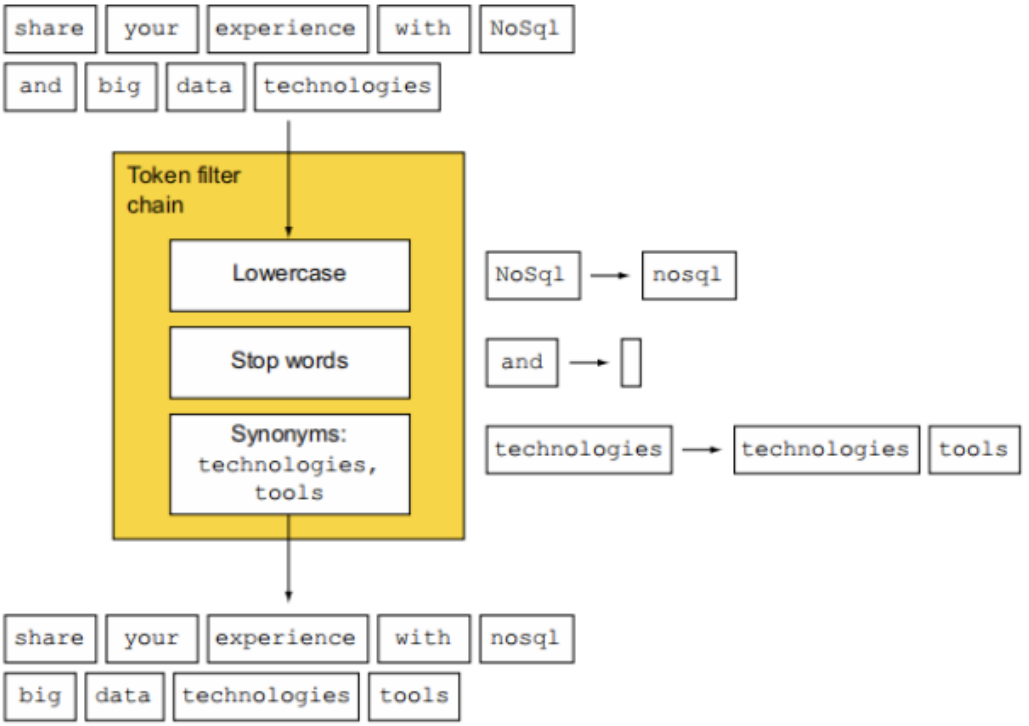

- **Fuzzy searching (i.e. similar words also work)**:
  - link: https://hackernoon.com/how-to-use-fuzzy-query-matches-in-elasticsearch-dh1h3167
  - Solution: We add *fuzziness* attribute to field that we need to search while querying.

```
"match": {
  "title.default": {
    "query":"eRçort",
    "fuzziness": "AUTO",
    "fuzzy_transpositions": "true"
  }
}
```

- **Auto-Complete suggestion**
  - Defined an example for auto-complete by using *completion suggester* in step 8. Auto-complete works with prefix. As documentation, if we need suggestion, then we should use suggester, not matching approach. Suggester mechanism is very fast. Here is the logic of suggester:

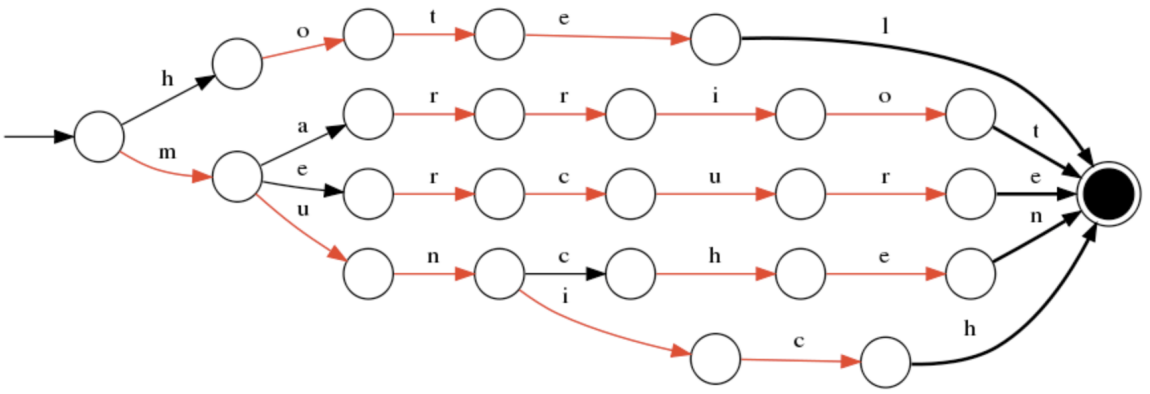

TF-IDF, Term Frequency * Inverse Document Frequency
Term Frequency, verilen dökümanda terimin ne sıklık ile geçtiğidir
Document Frequency, verilen tüm dökümanlarda terimin ne sıklıkla geçtiğidir

Her document bir _version'a sahiptir. Elasticsearch document'leri immutable'dır. Mevcut bir document'i update ettiğimizde; _version artırılarak yeni bir döküman oluşturulur ve eski olan deleted olarak marklanır. Partial update yapabiliriz.

Bir dökümanda count'u bir artıracak şekilde update etmek istediğimizde; mevcut count'u alır üzerine 1 ekler update ederiz. Fakat bunu 2 kişi yaptığında. count sadece 1 artmış olacak. Bunu çözmek için Optimistic Concurrency Control yaklaşımını kullanırız. Bunu seq_no & primary_term ile yaparız:

```
curl -XPUT localhost:9200/movies/_doc/10?if_sql_no=7&if_primary_term=1 -d '{
    "genres":["IMAX"],
    "title": "Intersteller"
}
```

Bir index'e yeni field'lar eklendiğinde; tüm cluster içerisindeki node'lar güncellenmesi gerekir. Bunu yaparken diğer search ve index çağrılarına cevap veremeyebilir. Inner field içeren field'larda Flattened data type kullanılır. Fakat bu tanımda field'lar partial match yapılmaz çünkü analyzer tanımlanmamıştır. Flatten yapılırken buna dikkat edilmesi gerekiyor.
